



INSTALLATION AND DEPLOYMENT MANUAL

PROJECT 2: Colon Cancer Medical
Diagnosis Simulator

JiaJiao Xu, Jordi Vidal
GROUP 2

Contents

Introducción.....	2
Requisitos del sistema	2
Hardware mínimo	2
Software requerido.....	2
Instalación paso a paso.....	3
1. Clonar el repositorio	3
2. Crear el entorno virtual de Python	3
3. Instalar dependencias Python.....	3
4. Instalar paquetes R (opcional)	3
5. Verificar instalación.....	4
Descarga de los datasets.....	4
Dataset clínico.....	4
Dataset CT (Medical Segmentation Decathlon).....	4
Estructura del proyecto	5
Resolución de problemas comunes	6
La aplicación no arranca	6
Error "ModuleNotFoundError"	6
Error al cargar el modelo CT (PyTorch 2.6+)	6
La pestaña "Análisis estadístico" aparece vacía.....	6
El modelo CT tarda mucho.....	6
La interfaz se ve mal o sin estilos.....	6
Encoding de acentos en Windows	6
Mantenimiento	7
Actualización de dependencias.....	7
Reentrenamiento del modelo clínico	7
Reentrenamiento del modelo CT.....	7
Backup.....	7

Introducción

Este manual describe los pasos necesarios para instalar y configurar el Simulador de Diagnóstico de Cáncer de Colon en un equipo nuevo. Está pensado para usuarios con conocimientos básicos de línea de comandos.

Tras seguir este manual completo, tendrás el sistema funcionando localmente en `http://localhost:8501` y podrás usar todas las funcionalidades de la aplicación (riesgo clínico, análisis CT, gráficos R y documentación).

Tiempo estimado de instalación: 20-30 minutos en condiciones normales. Si necesitas reentrenar los modelos desde cero, añadir varias horas más para descargar datos y entrenar.

Requisitos del sistema

Hardware mínimo

- Procesador: Intel Core i5 8.^a generación o equivalente.
- Memoria RAM: 8 GB mínimo, 16 GB recomendado.
- Espacio en disco: 5 GB para código, modelos entrenados y datos procesados.
- GPU (opcional pero recomendado): NVIDIA con CUDA 11.8 o superior. Acelera el modelo CT de 3 segundos a 0.3 segundos por imagen.

Software requerido

Software	Versión	Obligatorio
Sistema operativo	Windows 10/11, macOS 12+, Ubuntu 20.04+	Sí
Python	3.11 o superior	Sí
Git	2.30 o superior	Sí
Navegador web	Chrome, Firefox o Edge actual	Sí
R	4.5.3 o superior	Solo para análisis estadístico
Visual Studio Code	Última versión	Recomendado
CUDA Toolkit	11.8 o superior	Solo si tienes GPU NVIDIA

Instalación paso a paso

1. Clonar el repositorio

Abre una terminal (PowerShell en Windows, Terminal en macOS/Linux) y ejecuta:

```
git clone https://github.com/[tu-usuario]/colon_cancer_ai.git cd colon_cancer_ai
```

2. Crear el entorno virtual de Python

Es muy recomendable usar un entorno virtual para no contaminar la instalación global de Python:

```
python -m venv .venv
```

Activa el entorno virtual:

```
# Windows PowerShell .venv\Scripts\Activate.ps1 # macOS / Linux source  
.venv/bin/activate
```

Si en Windows aparece el error "Cannot be loaded because running scripts is disabled", ejecuta una sola vez:

```
Set-ExecutionPolicy -ExecutionPolicy RemoteSigned -Scope CurrentUser
```

A partir de ahora, al inicio de la línea verás "(.venv)" indicando que el entorno está activo.

3. Instalar dependencias Python

Con el entorno virtual activo, actualiza pip y luego instala todas las dependencias:

```
pip install --upgrade pip pip install -r requirements.txt
```

Si tienes GPU NVIDIA y quieres acelerar el modelo CT, instala PyTorch con soporte CUDA:

```
pip install torch torchvision --index-url https://download.pytorch.org/whl/cu118
```

Verificación de GPU: `python -c "import torch; print('CUDA:', torch.cuda.is_available())"`.

Debe mostrar "CUDA: True" si quieres aceleración por GPU.

4. Instalar paquetes R (opcional)

Solo si quieres regenerar los gráficos del análisis estadístico. Abre una sesión de R y ejecuta:

```
install.packages(c("tidyverse", "ggplot2", "ggcorrplot", "broom",  
"pROC", "scales", "gridExtra"))
```

5. Verificar instalación

Para comprobar que todo está correcto:

```
# Verificar Python y librerías principales python -c "import streamlit, torch,
sklearn; print('Python OK')" # Verificar R (opcional) Rscript -e
"library(tidyverse); library(pROC); cat('R OK\n')" # Lanzar la aplicación
streamlit run app/app_streamlit.py
```

Si todo está bien instalado, se abrirá automáticamente el navegador en <http://localhost:8501> con la aplicación funcionando.

Descarga de los datasets

Los modelos entrenados están incluidos en el repositorio. Solo necesitas descargar los datasets si quieres reentrenar los modelos desde cero.

Dataset clínico

1. Crear cuenta gratuita en <https://www.kaggle.com>
2. Buscar "Colorectal Cancer Risk Factors" en Kaggle Datasets.
3. Descargar el archivo CSV.
4. Colocarlo en `data/raw/colorectal_cancer_dataset.csv`
5. Ejecutar el pipeline de preprocesado:

```
python src/python/01_limpiar_dataset.py python src/python/02_generar_controles.py
python src/python/03_construir_dataset.py
```

Dataset CT (Medical Segmentation Decathlon)

6. Ir a <http://medicaldecathlon.com/>
7. Descargar Task10_Colon.tar (~7 GB).
8. Descomprimir en `data/raw/Task10_Colon/`
9. Ejecutar el preprocesado a slices 320x320 (versión v5):

```
python src/python/preprocesar_msd_colon_slices_320.py
```

O en su defecto a 256x256 para la versión v4 (producción):

```
python src/python/preprocesar_msd_colon_slices_256.py
```

Tiempo estimado: Preprocesar el dataset CT tarda 5-10 minutos. Resultado: ~13 000 slices en `data/processed/msd_colon_slices_*/`

Estructura del proyecto

La organización del proyecto sigue este esquema:

```
colon_cancer_ai/
├── app/
│   ├── app_streamlit.py           # Main application
│   └── assets/
│       └── styles.css             # CSS styles
├── src/
│   ├── python/
│   │   ├── utils/                # Auxiliary modules
│   │   │   ├── paciente_schema.py
│   │   │   ├── risk_levels.py
│   │   │   ├── calculadora_riesgo_literatura.py
│   │   │   └── decision_combinada.py
│   │   ├── 01_limpiar_dataset.py
│   │   ├── 02_generar_controles.py
│   │   ├── 03_construir_dataset.py
│   │   ├── 04_entrenar_modelo.py
│   │   ├── 10_calibracion.py
│   │   ├── 11_risk_stratification.py
│   │   ├── 12_evaluar_calculadora_literatura.py
│   │   ├── 13_evaluar_modelo_ct.py
│   │   ├── entrenar_msdcolon_unet_v4.py      # CT v4 (production)
│   │   ├── entrenar_msdcolon_unet_v5.py      # CT v5 (experimental)
│   │   ├── evaluar_msdcolon_unet_cached.py
│   │   ├── preparar_msdcolon.py
│   │   ├── preprocesar_msdcolon_slices_256.py
│   │   └── preprocesar_msdcolon_slices_320.py
│   └── r/
│       ├── 01_analisis_exploratorio.R
│       ├── 02_regresion_logistica.R
│       └── 03_visualizaciones_memoria.R
├── data/                          # Data (not included in Git due to size)
│   ├── raw/                       # Original datasets
│   └── processed/                  # Processed datasets
├── models/                        # Trained weights (not included in Git)
│   ├── calibrated_model.joblib     # Calibrated clinical model
│   ├── msdcolon_unet_cached_best.pth # CT v4
│   └── msdcolon_unet_v5_best.pth   # CT v5
├── reports/                       # R output files (PNG)
│   ├── eda/
│   ├── regresion_logistica/
│   └── memoria/
├── docs/                          # Project documentation
│   ├── usermanual.pdf
│   ├── instalationmanual.pdf
│   └── maindocumentation.pdf
├── tests/
│   └── test_model1.py
├── .gitignore
├── README.md
└── requirements.txt
```

Resolución de problemas comunes

La aplicación no arranca

Verifica que el entorno virtual está activado. El prompt debe mostrar "(.venv)" al inicio. Si no, activa con `.venv\Scripts\Activate.ps1` (Windows) o `source .venv/bin/activate` (Mac/Linux).

Verifica que estás en la raíz del proyecto: el comando `streamlit run` debe ejecutarse desde `colon_cancer_ai/`, no desde dentro de `app/`.

Error "ModuleNotFoundError"

Reinstala las dependencias: `pip install --upgrade -r requirements.txt`. Si falla algún paquete específico, instálalo individualmente para ver el error real.

Error al cargar el modelo CT (PyTorch 2.6+)

PyTorch 2.6 cambió el comportamiento por defecto de `torch.load`. Si ves un error como "UnpicklingError: Weights only load failed", verifica que `app/app_streamlit.py` usa `torch.load(..., weights_only=False)` en la función `cargar_modelo_ct()`.

La pestaña "Análisis estadístico" aparece vacía

Significa que los gráficos R aún no se han generado. Ejecuta los tres scripts R desde la raíz del proyecto y refresca la página con `Ctrl+F5`:

```
Rscript src/r/01_analisis_exploratorio.R Rscript src/r/02_regresion_logistica.R  
Rscript src/r/03_visualizaciones_memoria.R
```

El modelo CT tarda mucho

Sin GPU una predicción puede tardar 5-10 segundos. Si dispones de GPU NVIDIA, asegúrate de tener PyTorch con CUDA. Verifica con: `python -c "import torch; print(torch.cuda.is_available())"`.

La interfaz se ve mal o sin estilos

Streamlit a veces cachea CSS antiguo. Pulsa `Ctrl+F5` para recarga forzada sin caché. Si persiste, cierra el servidor (`Ctrl+C` en la terminal) y vuelve a lanzarlo.

Encoding de acentos en Windows

Si los acentos aparecen como caracteres extraños, configura PowerShell para UTF-8:

```
[Console]::OutputEncoding = [System.Text.Encoding]::UTF8
```

Mantenimiento

Actualización de dependencias

Periódicamente conviene actualizar las dependencias para incorporar mejoras de seguridad y rendimiento. Antes de actualizar, congela las versiones actuales por si necesitas revertir:

```
pip freeze > requirements_backup.txt pip install --upgrade -r requirements.txt
```

Reentrenamiento del modelo clínico

Si se incorporan nuevos datos, ejecuta el pipeline completo:

```
python src/python/01_limpiar_dataset.py python src/python/02_generar_controles.py  
python src/python/03_construir_dataset.py python src/python/04_entrenar_modelo.py  
python src/python/10_calibracion.py python src/python/11_risk_stratification.py
```

Reentrenamiento del modelo CT

Para la versión v4 (producción):

```
python src/python/preprocesar_msd_colon_slices_256.py python  
src/python/entrenar_msd_colon_unet_v4.py
```

Para la versión v5 (experimental):

```
python src/python/preprocesar_msd_colon_slices_320.py python  
src/python/entrenar_msd_colon_unet_v5.py python  
src/python/evaluar_msd_colon_unet_v5.py
```

Tiempo de entrenamiento: Modelo clínico: 1-2 minutos. Modelo CT v4: 1-2 horas con GPU.
Modelo CT v5: 2-4 horas con GPU.

Backup

Carpetas críticas a incluir en backup:

- models/ (pesos entrenados)
- data/processed/ (datasets limpios)
- reports/ (gráficos R)
- src/ (código fuente)

Las carpetas data/raw/ y .venv/ pueden regenerarse y no requieren backup.