



PROYECTO 2:

SIMULADOR DE DIAGNÓSTICO MÉDICO DE CÁNCER DE COLON

Jiajiao Xu y Jordi Vidal

Stucom



Índex

Introducción	3
Objetivos y requisitos del proyecto.....	4
Objetivos.....	4
Requisitos funcionales	4
Requisitos no funcionales	4
Análisis previo	6
El problema de los datos disponibles	6
Criterio adoptado	6
Origen de los datos	7
Dataset clínico.....	7
Dataset de imagen CT.....	8
Tratamiento de datos	8
Análisis de tecnologías	9
Librerías de Python	9
Análisis estadístico en R	9
Aplicación web	10
Arquitectura del sistema	11
Casos de uso	11
Diagramas	12
Flujo de cálculo	13
Definición de los modelos usados	14
Modelo 1A — Random Forest clínico	14
Modelo 1B — Calculadora de literatura.....	14
Modelo 2 — U-Net para imagen CT	16
Decisión combinada	16
Diseño de la interfaz (UI/UX).....	17
Principios de diseño aplicados	17
Estructura de navegación	17
Patrón visual de la pestaña Riesgo clínico	17

Visualización de resultados	17
Tarjetas por motor	17
Tarjeta de decisión combinada.....	17
Chips de factores	18
Visualización CT	18
Resultados de pruebas unitarias, de integración y de aceptación	19
Pruebas unitarias.....	19
Pruebas de integración	19
Pruebas de aceptación	20
Análisis de precisión y rendimiento	21
Métricas del Modelo 1A (clínico)	21
Métricas del Modelo 2 (CT)	21
Rendimiento técnico	21
Conclusiones y mejoras futuras	23
Conclusiones.....	23
Mejoras futuras.....	23
Vídeo del simulador	24
Enlace GitHub.....	24

Introducción

El objetivo de este proyecto era diseñar y desarrollar un software de apoyo al diagnóstico médico de cáncer de colon usando técnicas de Inteligencia Artificial. El sistema debe ayudar a estimar el riesgo de un paciente y a detectar regiones sospechosas en imágenes de tomografía computarizada (CT).

El cáncer colorrectal es el tercer tumor más frecuente del mundo. Cuando se detecta tarde, mata a uno de cada tres pacientes. Cuando se detecta pronto, se cura en la mayoría de los casos. Por eso es tan importante saber a quién hay que cribar antes.

La solución desarrollada combina tres motores complementarios: un modelo de Machine Learning entrenado con datos clínicos, una calculadora de riesgo basada en literatura científica publicada (estilo NCI CCRAT), y un modelo de Deep Learning (U-Net) que segmenta posibles tumores en cortes axiales de CT. Los resultados se integran en una decisión combinada con peso 70% literatura + 30% Machine Learning, más criterios clínicos específicos basados en guías NCCN y ESMO.

Todo se presenta en una aplicación web interactiva desarrollada con Streamlit, que permite al usuario explorar el riesgo de un paciente, subir una imagen CT, consultar el análisis estadístico complementario y leer la documentación del sistema.

Objetivos y requisitos del proyecto

Objetivos

El objetivo principal es construir un sistema de apoyo al diagnóstico que sea robusto, transparente y reconozca abiertamente sus limitaciones. El proyecto tiene los siguientes objetivos:

Construir un sistema de apoyo al diagnóstico robusto y transparente.

Estimar la probabilidad de cáncer mediante variables clínicas y de estilo de vida.

Implementar una calculadora de riesgo absoluto a 5 años basada en el NCI CCRAT.

Segmentar tumores en imágenes CT con Deep Learning.

Diseñar una decisión combinada ponderada (70% literatura, 30% ML).

Requisitos funcionales

El sistema deberá cumplir con los siguientes requisitos funcionales:

- Permitir la entrada de datos clínicos del paciente mediante un formulario de 13 campos.
- Validar la consistencia y rango de los datos introducidos antes del cálculo.
- Calcular la probabilidad de cáncer mediante el modelo ML calibrado.
- Calcular el riesgo absoluto a 5 años mediante la calculadora de literatura.
- Combinar ambos resultados con la fórmula 70% literatura + 30% ML.
- Aplicar criterios clínicos: si hay mutación o EII, elevar el nivel a Alto. Si concurren 5+ factores modificables, elevar mínimo a Medio.
- Detectar discrepancias entre motores y avisar al usuario.
- Permitir la subida de imágenes CT en formato .npz, .npy, .png o .jpg.
- Procesar la imagen y mostrar la región sospechosa resaltada en rojo.
- Mostrar las gráficas estadísticas generadas en R.

Requisitos no funcionales

- Usabilidad: la aplicación debe ser intuitiva para usuarios sin formación técnica avanzada.
- Rendimiento: el cálculo del riesgo clínico debe completarse en menos de 2 segundos en un PC normal.
- Portabilidad: la solución debe poder ejecutarse en Windows, macOS y Linux con Python 3.11+.
- Mantenibilidad: el código debe estar modularizado y comentado para facilitar futuras ampliaciones.

- Robustez: el sistema debe gestionar de forma controlada errores en los datos de entrada.
- Reproducibilidad: dadas las mismas entradas y parámetros, los resultados deben ser coherentes.
- Transparencia: todas las decisiones del sistema deben ser explicables al usuario.

Análisis previo

El problema de los datos disponibles

Durante el análisis inicial detectamos un problema importante con el dataset clínico disponible. El dataset de Kaggle "Colorectal Cancer Risk Factors" contiene 167 497 registros, pero todos son casos positivos (pacientes con cáncer ya diagnosticado). Para entrenar un clasificador binario necesitamos también controles, es decir, pacientes sin cáncer.

No existe un dataset público de controles con las mismas variables. Las opciones eran tres: descartar el proyecto, buscar otro dataset (que tampoco existía) o generar controles sintéticos. Optamos por la tercera, asumiendo conscientemente las limitaciones que esto conlleva.

Generamos 167 497 controles sintéticos usando las distribuciones marginales de la población española según datos del INE. Las distribuciones por edad, sexo, IMC, hábitos, etc., son coherentes con la población general. Pero las correlaciones entre variables no necesariamente reflejan la realidad clínica. Por ejemplo, en los datos reales hay correlación entre obesidad y diabetes; en nuestros controles sintéticos esa correlación puede ser distinta.

Criterio adoptado

Para abordar el problema del dataset sintético se ha adoptado un criterio claro: NO confiar al 100% en el modelo de Machine Learning entrenado sobre estos datos. En su lugar, se ha diseñado un sistema dual donde la calculadora de literatura (basada en miles de pacientes reales y meta-análisis validados) tiene mayor peso (70%) que el modelo ML (30%).

Para validar este criterio cuantitativamente, se ha realizado un análisis estadístico complementario en R. Se ha entrenado una regresión logística clásica sobre el mismo dataset y se han calculado los Odds Ratios (OR) con sus intervalos de confianza al 95%. Después se han comparado estos OR con los Riesgos Relativos (RR) publicados en la literatura científica.

El análisis ha revelado tres casos de inversiones críticas:

Factor	OR del modelo	RR de literatura	Discrepancia
Mutación genética	1.67	4.00	Atenuación del 58%
Sedentarismo	0.91	1.32	INVERSIÓN: aparece como protector
Dieta moderada vs alta	2.01 vs 1.42	1.10 vs 1.25	Orden invertido

Decisión clave: Estas inversiones se atribuyen a la generación sintética de los controles. En lugar de ocultar este problema, lo convertimos en la justificación cuantitativa del diseño dual-motor. Es la decisión más importante del proyecto.

Origen de los datos


Dataset clínico

El dataset principal es "Colorectal Cancer Risk Factors", disponible en Kaggle. Contiene 167 497 registros de pacientes con cáncer colorrectal y 28 variables que cubren datos demográficos, clínicos, hábitos, tratamientos y resultados.

Colorectal Cancer Global Dataset & Predictions

Predicting Colorectal Cancer Outcomes Based on Global Health Trends

[Data Card](#) [Code \(13\)](#) [Discussion \(3\)](#) [Suggestions \(0\)](#)



Tras un proceso de limpieza y selección, se conservan 13 variables que pueden recogerse en consulta sin pruebas invasivas:

Variable	Tipo	Descripción
Edad	Numérica	Edad en años (rango 18-90)
Género	Categórica	Hombre / Mujer
Antecedentes familiares	Binaria	Familiar 1.er grado con CCR
Tabaquismo	Binaria	Fumador activo
Alcohol	Binaria	Consumo regular
IMC	Categórica	Normal / Sobrepeso / Obesidad
Dieta	Categórica	Bajo / Moderado / Alto riesgo
Actividad física	Categórica	Baja / Moderada / Alta
Diabetes	Binaria	Diabetes tipo 2
EII	Binaria	Enfermedad inflamatoria intestinal
Mutación genética	Binaria	Lynch, FAP, MUTYH conocidas
Urbano/Rural	Binaria	Entorno residencial
Acceso sanitario	Categórica	Bueno / Limitado

Dataset de imagen CT

Para el modelo de imagen se utiliza el Medical Segmentation Decathlon (MSD), Task 10 Colon. Es un dataset público y anonimizado con 126 volúmenes CT de pacientes con cáncer colorrectal anotados píxeles a píxel por radiólogos especialistas. Se presentó por Antonelli et al. en 2022 en Nature Communications.

Tras el preprocesado se obtienen aproximadamente 13 000 slices axiales en total. La división se hace por paciente (no por slice) para evitar fugas: 80% pacientes para entrenamiento (~10 953 slices) y 20% para validación (~2 533 slices).

Tratamiento de datos

Pipeline aplicado al dataset clínico (scripts 01-08 en src/python/):

1. Limpieza: eliminación de duplicados, gestión de valores faltantes, validación de rangos.
2. Generación de controles sintéticos con distribuciones marginales del INE.
3. Construcción del dataset binario con etiqueta y/n.
4. Split estratificado train/test 80/20.
5. Entrenamiento del modelo Random Forest.
6. Calibración isotónica con CV=3.
7. Estratificación en niveles Bajo/Medio/Alto.

Pipeline aplicado al dataset CT:

8. Lectura de los volúmenes .nii.gz con nibabel.
9. Normalización por percentiles 1-99 al rango [0, 1].
10. Redimensionado de cada slice axial a 320x320 (versión final).
11. Replicación del canal único en 3 canales para compatibilidad con encoders preentrenados.
12. Guardado en formato .npz comprimido para acelerar el entrenamiento.

Análisis de tecnologías

Desglose de las tecnologías usadas en el proyecto, organizadas por bloque funcional.

Librerías de Python

Librería	Versión	Propósito
streamlit	>= 1.30	Aplicación web interactiva
pandas	>= 2.0	Manipulación de datasets tabulares
numpy	>= 1.24	Cálculo numérico
scipy	>= 1.10	Resize y operaciones científicas
scikit-learn	>= 1.4	Random Forest, calibración, métricas
joblib	>= 1.3	Serialización del modelo ML
torch	>= 2.0	Framework de Deep Learning
segmentation_models_pytorch	>= 0.3	U-Net con encoders preentrenados
nibabel	>= 5.0	Lectura de volúmenes médicos .nii.gz
Pillow	>= 10.0	Procesado de imágenes PNG/JPG
matplotlib	>= 3.7	Visualizaciones internas

Análisis estadístico en R

Para el análisis estadístico complementario se ha optado por R en lugar de Python. R tiene mayor tradición en estadística inferencial y produce gráficos de calidad publicación con ggplot2.

Paquete R	Propósito
tidyverse	Manipulación y limpieza de datos
ggplot2	Gráficos de alta calidad
ggcorrplot	Correlogramas
broom	Extracción ordenada de coeficientes

Paquete R	Propósito
pROC	Curvas ROC con bootstrap
scales	Formateo de ejes
gridExtra	Composición de paneles

Arquitectura del sistema

Casos de uso

El sistema atiende a tres tipos de actores con distintas necesidades:


Actor	Caso de uso principal
Estudiante de medicina o IA	Experimentar con casos hipotéticos para entender la aplicación de IA al diagnóstico
Profesional sanitario	Explorar las posibilidades del ML aplicado a su especialidad
Profesor evaluador	Verificar funcionalidades, métricas y razonamiento durante la defensa del TFM

Casos de uso principales:

- CU-01: Evaluar el riesgo clínico de un paciente. Rellenar formulario, pulsar evaluar, obtener nivel + recomendación.
- CU-02: Analizar una imagen CT. Subir archivo, ver imagen procesada con región sospechosa resaltada.
- CU-03: Consultar análisis estadístico en R. Revisar gráficos de EDA, regresión logística y validación.
- CU-04: Consultar la documentación. Revisar arquitectura, fuentes científicas y glosario.


Diagramas

Diagrama de capas del sistema:



Flujo de cálculo

Flujo de una predicción típica al pulsar el botón "Evaluar riesgo clínico":



Definición de los modelos usados

Modelo 1A — Random Forest clínico

El primer motor es un Random Forest de 300 árboles entrenado sobre las 13 variables clínicas seleccionadas. La elección frente a alternativas como gradient boosting o redes neuronales se justifica por su robustez con datasets de tamaño medio, su interpretabilidad parcial y su capacidad de manejar variables mixtas sin preprocesado complejo.

Hiperparámetros:

- Número de árboles: 300
- Profundidad máxima: 12
- Mínimo de muestras por hoja: 20
- Class weight: balanced
- Calibración: isotónica con validación cruzada de 3 folds
- Umbrales de estratificación: 0.30 (Bajo) y 0.70 (Alto)

Modelo 1B — Calculadora de literatura

El segundo motor implementa la fórmula NCI CCRAT: Riesgo a 5 años = Tasa basal SEER × Producto de los Riesgos Relativos del paciente. Las tasas basales se obtienen del NCI estratificadas por edad y sexo. Los Riesgos Relativos provienen de meta-análisis publicados.

Factor	RR	Fuente
Mutación genética conocida	4.00	NCI CCRAT
Enfermedad inflamatoria intestinal (EII)	2.93	Johnson 2013
Antecedentes familiares 1.er grado	1.79	Butterworth 2006
Obesidad (IMC ≥ 30)	1.33	Ma 2013
Diabetes tipo 2	1.27	Johnson 2013
Dieta alto riesgo	1.25	Johnson 2013
Alcohol regular	1.21	Johnson 2013
Tabaquismo	1.18	Johnson 2013
Sobrepeso (IMC 25-29.9)	1.10	Ma 2013

Factor	RR	Fuente
Dieta moderado riesgo	1.10	Johnson 2013
Actividad moderada	0.88	Johnson 2013 (protector)
Actividad alta	0.76	Johnson 2013 (protector)

Modelo 2 — U-Net para imagen CT

El tercer motor es una red U-Net para segmentación de tumores en imagen CT. La arquitectura U-Net (Ronneberger, 2015) tiene forma de "U": un encoder que comprime la imagen para captar contexto, un decoder que la expande para localizar píxel a píxel, y conexiones laterales (skip connections) que preservan el detalle.

El modelo se desarrolló iterativamente. Probamos cinco versiones:

Versión	Cambios principales	AUC	Dice+
v1	U-Net pequeña, 192x192, BCE pura	0.677	0.24
v2	Dropout + augmentation	collapse	—
v3	Focal loss	0.729	0.00
v4 (deployment)	ResNet-34 + Tversky, 256x256	0.796	0.470
v5 (experimental)	EfficientNet-B0, 320x320	0.970	0.388

Decisión sobre la versión final: La versión v4 (ResNet-34 + Tversky a 256px) sigue siendo la usada en producción por su mejor Dice. La versión v5 alcanza un AUC altísimo pero su Dice es ligeramente peor y muestra inestabilidad tras la época 17 (overfitting al augmentation agresivo). Documentamos ambas versiones como evidencia del proceso iterativo.

Decisión combinada

El sistema de decisión combinada sigue este algoritmo:

13. Calcular score ponderado: $\text{score} = 0.70 \cdot \text{literatura_normalizada} + 0.30 \cdot \text{ML_probabilidad}$
14. Estratificar por score: $> 0.55 \rightarrow \text{Alto}$, entre 0.25 y 0.55 $\rightarrow \text{Medio}$, $< 0.25 \rightarrow \text{Bajo}$
15. Aplicar override clínico: mutación o EII fuerza nivel Alto
16. Aplicar boost: 5+ factores modificables eleva mínimo a Medio
17. Detectar discrepancia: si ML y literatura difieren 2 niveles, alerta visible
18. Generar recomendación clínica adaptada al nivel

Por qué peso 70/30: La literatura está basada en cohortes reales con cientos de miles de pacientes y meta-análisis validados. El ML, entrenado parcialmente sobre controles sintéticos, presenta inversiones de coeficientes (sección "Análisis previo"). La ponderación refleja esta diferencia de fiabilidad.

Diseño de la interfaz (UI/UX)

Principios de diseño aplicados

- Claridad.
- Tono profesional médico: paleta azul oscuro + verde turqués.
- Niveles de riesgo en código de colores universal: verde / ámbar / rojo (semáforo).

Estructura de navegación

La aplicación usa una navegación por pestañas centradas con 4 secciones:

19. Riesgo clínico: pantalla principal donde se introducen los datos del paciente.
20. Imagen CT: análisis radiológico con detección de regiones sospechosas.
21. Análisis estadístico: gráficos generados en R sobre los hallazgos del estudio.
22. Información: documentación completa, fuentes científicas y glosario.

Patrón visual de la pestaña Riesgo clínico

Tras pulsar "Evaluar", la pantalla se organiza en 3 secciones jerárquicas:

- ARRIBA: dos tarjetas paralelas, una por motor. Valor grande + desplegable explicativo.
- CENTRO: tarjeta destacada con la decisión combinada, gauge horizontal y motivo.
- ABAJO: chips coloreados de factores detectados (rojos riesgo, verdes protectores).

Visualización de resultados

Los resultados del cálculo se presentan al usuario de forma jerárquica para guiar la lectura: primero el detalle por motor, después la decisión combinada, finalmente los factores que la sustentan.

Tarjetas por motor

Dos tarjetas en paralelo. Cada una muestra: el nombre del motor, el valor numérico grande (probabilidad ML o riesgo a 5 años), un badge con el nivel de riesgo (Bajo/Medio/Alto) y un desplegable "¿Cómo se calcula este valor?" con el detalle técnico. Esto permite al usuario entender el razonamiento de cada motor de forma independiente.

Tarjeta de decisión combinada

Tarjeta destacada con: el nivel final, un gauge horizontal con gradiente verde-amarillo-rojo, el score numérico, el desglose paso a paso (peso literatura, peso ML, criterios clínicos aplicados, discrepancias detectadas) y la recomendación clínica adaptada.

Chips de factores

Lista de factores detectados como chips coloreados. Los rojos indican factores de riesgo y los verdes factores protectores. Cada chip muestra el RR multiplicador, lo que permite al usuario ver qué pesa más en la decisión final.

Visualización CT

Para imagen CT: la imagen original a la izquierda, la imagen procesada con la región sospechosa resaltada en rojo a la derecha. Debajo: la probabilidad estimada y la recomendación. Un desplegable explica el funcionamiento de la red U-Net en lenguaje accesible.

Resultados de pruebas unitarias, de integración y de aceptación

Pruebas unitarias

Se han verificado las funciones individuales del sistema. Las pruebas pasan al 100%:

- Validación del esquema de paciente: 7 tests (rangos de edad, género, valores categóricos válidos).
- Calculadora de literatura: 5 tests (multiplicación de RR, saturación, riesgo lifetime > 5 años).
- Niveles de riesgo: 7 tests (umbrales 0.30 y 0.70, casos límite).
- Función de combinación: producto de pesos correcto, normalización de literatura, override clínico.

Pruebas de integración

Verifican que múltiples módulos colaboran correctamente:

Test	Escenario	Resultado esperado	Estado
T-I-01	Joven sano sin factores	Bajo	PASA
T-I-02	Mutación genética sola	Alto (override)	PASA
T-I-03	EII sola	Alto (override)	PASA
T-I-04	Mutación + EII	Alto (override doble)	PASA
T-I-05	5+ factores modificables	Medio (boost)	PASA
T-I-06	Discrepancia ML/Lit (Bajo vs Alto)	Alto + alerta	PASA
T-I-07	Predicción <2s en CPU	1.3s	PASA
T-I-08	Modelos cargan correctamente	Carga sin error	PASA

Pruebas de aceptación

Se han realizado pruebas manuales de usuario final con 5 escenarios representativos:

- 23. Paciente joven sano (30 años, mujer, sin factores) → Bajo, score 6%, gauge verde, recomendación de cribado a partir de 45-50.
- 24. Paciente alto riesgo crítico (65 años, mutación + EII) → Alto, override visible, recomendación de derivación inmediata.
- 25. Paciente con discrepancia entre motores → banner amarillo de discrepancia, prioriza literatura.
- 26. Análisis CT con slice positiva (colon_001_z052.npz) → región roja correctamente localizada, probabilidad >99%.
- 27. Pestaña Análisis estadístico → muestra forest plot OR vs RR con inversiones detectadas.

Análisis de precisión y rendimiento

Métricas del Modelo 1A (clínico)

Métrica	Valor	IC 95%	Interpretación
AUC	0.716	[0.713, 0.719]	Discriminación aceptable
Brier score	0.215	—	Calibración razonable
Sensibilidad	0.72	—	Detecta 72% de casos reales
Especificidad	0.61	—	39% de falsos positivos
F1-score	0.68	—	Equilibrio decente

Comparación: AUC del modelo (0.716) supera al CCRAT clásico (0.61 en validación externa) pero no llega al nivel de modelos con EHR completos (0.80, Hornbrook 2017).

Métricas del Modelo 2 (CT)

Métrica	v4 (producción)	v5 (experimental)	Comentario
AUC	0.796	0.970	v5 distingue mejor slices con/sin tumor
Dice (positivos)	0.470	0.388	v4 localiza mejor el tumor
Sensibilidad	0.732	0.878	v5 detecta más tumores
Especificidad	0.742	0.916	v5 menos falsos positivos

La v4 sigue siendo la versión de producción por su mejor Dice. La v5 mejora discriminación global pero localiza ligeramente peor. La inestabilidad observada después de la época 17 en v5 sugiere que el augmentation agresivo combinado con learning rate alto provoca pérdida de calibración. Se mantienen ambas versiones como evidencia del proceso iterativo.

Rendimiento técnico

Operación	Tiempo CPU	Tiempo GPU
Carga inicial de la app	4-6 s	4-6 s
Predicción Modelo 1A	<0.1 s	<0.1 s

Operación	Tiempo CPU	Tiempo GPU
Cálculo Modelo 1B	<0.01 s	<0.01 s
Inferencia CT (slice)	2-3 s	0.2-0.4 s
Render UI completo	0.3 s	0.3 s

Conclusión: El sistema es lo suficientemente rápido para uso interactivo (<2 s sin GPU para el flujo clínico).

Conclusiones y mejoras futuras

Conclusiones

Este trabajo ha demostrado que es viable construir un sistema híbrido de apoyo al diagnóstico de cáncer de colon que integre Machine Learning, evidencia científica publicada y análisis de imagen CT, siguiendo principios de transparencia y robustez clínica.

Los principales logros del proyecto son:

- Implementación funcional de tres motores complementarios.
- Análisis estadístico inferencial en R que ha permitido identificar las limitaciones del modelo y justificar cuantitativamente el diseño dual-motor.
- Sistema de decisión combinada que pondera ambos motores y aplica criterios clínicos basados en guías NCCN/ESMO.
- Modelo de imagen CT con AUC de 0.796 (v4) y 0.970 (v5) obtenido tras un proceso iterativo de cinco versiones.

Mejoras futuras

- Validación prospectiva sobre cohortes reales con dictamen ético y aprobación regulatoria.
- Ampliación del modelo CT a análisis volumétrico 3D con datasets más grandes (>500 pacientes).
- Incorporación de variables omics y panel genético específico (Lynch, FAP, MUTYH, MMR).
- Meta-modelo que aprenda automáticamente la ponderación óptima entre motores según el caso.
- Adaptación de tasas basales SEER a la población española y otras europeas.
- Despliegue en servidor con autenticación clínica y registro de uso (audit log).
- Marcado CE como herramienta de apoyo médico para uso clínico real.
- Estabilización del modelo v5 mediante regularización adicional o reducción del augmentation tras el warmup.

Vídeo del simulador

El vídeo de demostración del simulador está disponible en el siguiente enlace:

<https://youtu.be/R1agTE9yofI>

Enlace GitHub

<https://github.com/TheSky189/Colorectal-Cancer-Prediction>